



UNIVERSITÀ DI PARMA

DIPARTIMENTO DI SCIENZE MATEMATICHE, FISICHE E INFORMATICHE
Corso di Laurea Triennale in Informatica

Trascrittomica spaziale

CANDIDATO:
Matteo Cerinelli

RELATORE:
Prof. Vincenzo Bonnici

MATRICOLA:
294907

Indice

1	Introduzione	3
2	Concetti generali	5
2.1	Gene	5
2.1.1	Epigenoma	6
2.1.2	Trascrittoma	7
2.2	Trascrittomica spaziale	7
2.2.1	Casi d'uso	8
2.3	Algoritmi per la trascrittomica spaziale	12
2.3.1	Seurat	12
2.3.2	GraphST	12
2.3.3	Giotto	12
2.4	Limiti	13
3	Nozioni di base	15
3.1	Smoothing spaziale	17
3.2	Formato dei dati	19
3.3	Scanpy	20
	Bibliografia	23

Capitolo 1

Introduzione

L'introduzione deve contenere un riassunto del lavoro di Tesi. In particolare bisogna esprimere chiaramente e molto sinteticamente: contesto dello studio, motivazioni, contributo e conclusioni. Bisogna quindi fare un sommario dello studio ad alto livello, fornendo le intuizioni senza ricadere in dettagli tecnici. Anche lo stile dovrebbe essere più discorsivo rispetto alle parti tecniche della tesi.

Capitolo 2

Concetti generali

Dall'alba dei tempi tutto ciò che circonda l'uomo è stato fonte di curiosità e studio. Partendo dall'interesse di tutti i vari aspetti riguardanti l'essere umano e gli organismi viventi, con cui ci relazioniamo quotidianamente, si è sviluppata la branca della biologia

L'informatica, invece, la branca della scienza che si occupa dello studio e dell'elaborazione delle informazioni, è stata fin da sempre utilizzata come strumento per migliorare la qualità della vita dell'uomo[1]. Dalla prima calcolatrice meccanica, la *Pascalina*, inventata da Blaise Pascal nel 1644[2], alla *Macchina di Turing*, ideata da Alan Turing nel 1943[3], fino ai moderni computer quantistici, l'informatica ha sempre avuto un ruolo fondamentale nell'evoluzione della società umana.

Lo sviluppo di entrambe queste discipline col passare degli anni ha portato ad un'innovazione: la *bioinformatica*. La bioinformatica nasce dalla combinazione delle due materie prima elencate in quanto gli scienziati manifestavano sempre più l'esigenza di gestire i dati rilevati dalla biologia molecolare, questo perchè, spesso, i dati superano le decine di gigabyte e serviva un modo per poter interpretare più facilmente i campioni raccolti. Oggi la gran parte delle informazioni bioinformatiche possono essere reperite sul *National Center of Biotechnology Information (NCBI)* che fornisce banche dati gratuite e strumenti per la ricerca in biologia molecolare e bioinformatica[4].

2.1 Gene

Ogni organismo, eucariote o procariote, pluricellulare o unicellulare che sia, presenta una molecola fondamentale che contiene tutte le informazioni necessarie per costituire l'organismo, tale molecola è il DNA (acido desossiribonucleico). Il DNA è composto da subunità, chiamate nucleotidi¹, contenenti: un

¹Il nucleotide è l'unità di base che forma DNA e RNA

gruppo fosfato, uno zucchero pentoso e una base azotata. Una specifica sequenza di DNA forma un gene e, l'insieme di tutti i geni, genera il genoma che, oltre a racchiudere le informazioni genetiche, presenta anche le parti del DNA che non codificano proteine². Circa il 30% del DNA nel genoma umano si trova negli esoni e negli introni. I primi, gli esoni, sono sequenze che codificano gli aminoacidi, i quali, vengono espressi in proteine, i secondi, gli introni, invece non codificano nessuna proteina. Al giorno d'oggi sappiamo che il genoma umano presenta circa 20000 geni che codificano proteine[5]. Con il passare degli anni sono stati sequenziati molti genomi, sia di microrganismi che di animali, questo perché, l'interesse degli scienziati è quello di andare definire i processi evolutivi degli esseri viventi, ma, per ottenere dei risultati, è indispensabile andare a comparare numerosi genomi di organismi differenti.

La branca della bioinformatica è molto ampia, per questo, noi ci interesseremo principalmente del genoma. La bioinformatica ha un ruolo fondamentale negli studi della struttura del genoma, per esempio, nell'assemblaggio e annotazione di genomi, o nella caratterizzazione del profilo di espressione genica, generando informazioni cruciali per orientare i successivi studi di genomica funzionale, i quali, si avvalgono di una grande varietà di tecniche sperimentali[6].

Possiamo quindi dire che tutte le cellule di un organismo hanno lo stesso genoma, ma possono presentare epigenomi e trascrittomi molto diversi.

2.1.1 Epigenoma

L'*epigenoma* è una moltitudine di composti chimici e preteine che regolano il genoma su cosa fare senza cambiare la sequenza del DNA. Esso contiene le varie istruzioni per poter costruire le proteine necessarie per svolgere le diverse funzioni della cellula. L'epigenoma, poi, può attaccarsi al DNA e impartire diversi comandi, tra cui l'attivazione o la disattivazione di geni, o il controllo della produzione di determinate proteine all'interno della cellula stessa.

Un essere umano possiede trilioni di cellule distribuite nei tessuti: muscolare, nervoso e osseo e, ciascuna delle cellule che compongono i tessuti, presenta essenzialmente lo stesso genoma all'interno del nucleo³. Le differenze tra le cellule sono determinate da come e quando diversi gruppi di geni vengono attivati o disattivati in vari tipi di cellule. Se prendiamo, ad esempio, in esame le cellule specializzate nell'occhio, queste attivano specifici geni che producono proteine in grado di rilevare la luce, mentre le cellule specializzate nei globuli

²Le proteine sono macromolecole che si formano partendo dal DNA e che vanno a costituire i tessuti.

³il nucleo è una struttura subcellulare, presente negli eucarioti, che contiene il DNA.

rossi producono proteine che trasportano l'ossigeno dall'aria al resto del corpo. L'epigenoma quindi controlla molti di questi cambiamenti nel genoma[7].

2.1.2 Trascrittoma

Il DNA, non viene utilizzato direttamente per costruire le proteine: prima deve essere trascritto in RNA. Questo processo prende il nome di trascrizione e produce diversi tipi di RNA. Il *trascrittoma* rappresenta l'insieme di tutte le molecole di RNA presenti in una cellula in un dato momento.

L'RNA principale è l'RNA messaggero (mRNA) il quale trasporta le istruzioni dai geni ai ribosomi dove verranno generate le proteine mediante l'attività di sintesi proteica. Nei ribosomi, la sequenza di basi dell'mRNA viene letta e tradotta in catene di amminoacidi. Accanto all'mRNA, esistono anche altri tipi di RNA che non codificano proteine ma che svolgono funzioni regolatorie o strutturali, contribuendo a controllare l'attività dei geni e l'organizzazione della cellula. Poiché ogni cellula del corpo umano possiede lo stesso patrimonio genetico, ciò che la distingue dalle altre non è il genoma ma l'insieme dei geni che vengono attivati o silenziati. Questo insieme di trascrizioni geniche costituisce il trascrittoma, e varia notevolmente da cellula a cellula e da tessuto a tessuto. Ad esempio, le cellule muscolari esprimono geni che producono proteine contrattili, mentre le cellule nervose attivano geni che permettono la trasmissione dei segnali elettrici.

Il trascrittoma quindi è lo specchio dell'attività del genoma: mostra quali geni sono effettivamente in funzione in un determinato momento e fornisce informazioni preziose sull'identità, lo stato e la salute delle cellule[7].

2.2 Trascrittomica spaziale

Come detto in precedenza, il trascrittoma rappresenta l'insieme di tutte le molecole di RNA presenti in una cellula in un dato momento. La trascrittomica a singola cellula (scRNA-seq) è diventata essenziale per la ricerca biomedica nell'ultimo decennio, in particolare nello sviluppo della biologia, cancro, immunologia e neuroscienze.

La maggior parte dei protocolli scRNA-seq disponibili in commercio richiedono che le cellule siano recuperate intatte e vitali dai tessuti. Ciò ha precluso lo studio di molti tipi cellulari e ha in gran parte distrutto il contesto spaziale che altrimenti avrebbe potuto informare le analisi dell'identità e della funzione cellulare. Oggi, un numero crescente di piattaforme disponibili in commercio, consente di mappare l'espressione dell'RNA direttamente sulla struttura del tessuto, mantenendo l'informazione di posizione di ciascun segnale: questo approccio è noto come *trascrittomica spaziale (TS)*. La TS produce dati ad alta

dimensionalità utili a descrivere l'organizzazione cellulare e i processi biologici direttamente nel tessuto, preservandone la posizione[8].

Una sfida fondamentale nella TS è l'identificazione degli *Spatially Variable Genes (SVGs)*. Questi ultimi sono geni la cui espressione varia in modo dipendente dalla posizione nello spazio del tessuto. Analizzando lo spazio è possibile scovare pattern non casuali di espressione genica. Identificarli è cruciale nelle analisi di TS perché rivela domini tissutali, le quali sono nicchie cellulari e transizioni; In più facilita l'annotazione⁴ e quindi il clustering[9]. Oltre agli SVGs esistono anche gli *Highly Variable Genes (HVGs)*, geni, che presentano una variabilità di espressione molto superiore a quanto atteso, nonostante ciò non sono in grado di fornire informazioni spaziali rilevanti.




Figura 2.1: HVGs e SVGs a confronto

La figura 2.1 presenta un confronto tra HVGs e SVp alcuna iGs dato lo stesso Dataset. Si noti come gli HVGs non possiedono alcuna informazione spaziale, in quanto, non presentano alcun tipo di pattern; Gli SVGs, al contrario, mostrano una chiara suddivisione in cluster.

2.2.1 Casi d'uso

Il cancro rimane una sfida significativa per la salute globale. Nonostante i notevoli progressi compiuti negli ultimi decenni, il trattamento del cancro incontra ancora numerosi ostacoli, come la resistenza ai farmaci, la recidiva tumorale

⁴L'assegnazione di etichette biologiche a cluster o spot

e le metastasi. Utilizzando tecniche di sequenziamento trascrittomico ad alto rendimento, le RNA-seq, i ricercatori hanno scoperto numerose alterazioni dell'espressione genica specifiche del cancro in diversi tumori. Tuttavia, il sequenziamento dell'RNA in massa non può ottenere informazioni sull'ambiente tumorale e sull'eterogeneità cellulare[10].

La successiva comparsa del sequenziamento dell'RNA a singola cellula, la scRNA-seq, ha inaugurato una nuova era che consente lo studio dei trascrittommi a livello di singole cellule, facilitando analisi approfondite dell'eterogeneità cellulare e l'identificazione di diversi tipi cellulari. Tuttavia, come detto in precedenza, l'esecuzione del sequenziamento a singola cellula richiede che le cellule siano dissociate dal tessuto, causando una perdita di informazioni sulla loro posizione spaziale. Poiché la posizione spaziale delle cellule può effettivamente riflettere l'interazione tra le cellule, ed è strettamente correlata alle funzioni fisiologiche e patologiche, una nuova tecnologia che collega l'espressione genica alle informazioni sulla posizione spaziale è stata molto attesa. La trascrittomica spaziale rappresenta questa nuova tecnologia, e attraverso il suo utilizzo, è stata ottenuta una comprensione più completa dei meccanismi di inizio e progressione del tumore, offrendo nuove prospettive e opportunità per la diagnosi del cancro e il suo trattamento.

Ad esempio *Beyondcell* è una metodologia progettata per identificare le vulnerabilità ai farmaci utilizzando dati di trascrittomica spaziale. Viene assegnato un punteggio Beyondcell per ogni spot e coppia di farmaci, che va da 0 a 1, il quale indica la suscettibilità al farmaco. Gli spot vengono quindi classificati in cluster e i punteggi vengono visualizzati per comprendere l'efficacia terapeutica del campione[11].

Per poter recuperare le varie informazioni riguardanti l'espressione genica di un tessuto esistono diversi tipi di approcci[12].

Approcci basati sulla microdissezione mediante cattura laser La microdissezione a cattura laser (*Laser capture microdissection*, *LCM*) consente la dissezione accurata di singole cellule da sezioni di tessuto con notevole precisione, fornendo informazioni spaziali.

Come illustrato nella figura 2.2 il principio di base di questa tecnica è quello di fissare le sezioni di tessuto su vetrini, isolare le aree di interesse dal tessuto utilizzando LCM per poi metterle in soluzioni acquose⁵, quindi catturare l'espressione dei geni nel tessuto isolato tramite sequenziamento⁶.

⁵Per permettere la reazione enzimatica di ligazione, amplificazione e altre manipolazioni molecolari necessarie nella preparazione della library

⁶Determinare l'ordine dei nucleotidi in molecole di DNA per identificare e quantificare l'RNA in un campione biologico

Questo insieme di molecole di DNA preparate appositamente prendono il nome di *library*.

Analizzando le informazioni sull'espressione genica di ciascuna cellula, o regione separata, è possibile ricostruire la distribuzione spaziale e i profili di espressione genica di singole cellule o regioni all'interno del tessuto.



Figura 2.2: Tecniche di trascrittomica spaziale basate sulla microdissezione a cattura laser

Approcci basati sull'osservazione in situ Gli approcci basati sull'osservazione in situ⁷ rappresentano tecniche che permettono di osservare direttamente la distribuzione di RNA nel tessuto, senza necessità di estrazione preventiva, mantenendo il contesto spaziale originale. I due metodi più comunemente utilizzati sono l'ibridazione in situ (ISH) e il sequenziamento in situ (ISS).

Con l'ISH, vengono preparate molecole, chiamate sonde, di RNA che sono complementari agli RNA bersaglio; Le sonde si legano agli RNA nelle cellule o nel tessuto e sono marcate con molecole fluorescenti, così da poter essere visualizzate al microscopio. Questo processo permette di osservare dove e quanto è espresso un certo RNA. Nonostante ciò, queste tecniche richiedono molteplici cicli di ibridazione e osservazione, e possono essere soggette a rumore⁸.

Con l'ISS si aggiunge un livello in più: l'RNA viene localizzato e ne viene letta la sequenza direttamente nel tessuto.

Come già annunciato in precedenza la TS si è rivelata uno strumento rivoluzionario per quanto riguarda la ricerca sul cancro. I tumori, non essendo masse uniformi, sono composti da diverse famiglie cellulari con ruoli ben distinti. Comprendere spazialmente dove ogni cellula si trova e come interagisce con le cellule vicine è stato fondamentale per rivelare i meccanismi di crescita, progressione e resistenza terapeutica del tumore. L'utilizzo di questa tecnologia

⁷Dal latino: "nel luogo". Significa analizzare direttamente nel tessuto originale

⁸Forma di disturbo che si aggiunge al segnale utile

può facilitare la comprensione dei tipi e degli stati delle cellule che circondano il tumore, nonché delle loro interazioni con le cellule tumorali, rivelando così la complessità del microambiente tumorale (Tumor Microenvironment, TME). Infatti, alcuni studi hanno mappato con la trascrittomiche spaziale i tessuti di vari tumori e hanno confermato il ruolo cruciale del TME nella diagnosi clinica, nella progressione della malattia e nella risposta al trattamento, inclusa l'insorgenza di resistenza al trattamento nei tumori[12].




Figura 2.3: Applicazione della trascrittomiche spaziale nella ricerca sul cancro

Il cancro al polmone, ad esempio, è una delle principali cause di morte in ambito tumorale a livello globale ed è una malattia complessa con numerosi sottotipi, ognuno dei quali presenta esiti clinici diversi. Studi su masse tumorali polmonari, hanno rivelato che i macrofagi⁹ non si distribuiscono uniformemente: la loro composizione e posizione cambiano, influenzando il comportamento della malattia e la risposta alle terapie. Inoltre, l'integrazione tra TS e scRNA-seq ha permesso di identificare cellule rare, transizioni cellulari e sottopopolazioni spazialmente specifiche che altrimenti sarebbero rimaste inosservate.

⁹Cellule immunitarie che uccidono batteri, detriti e cellule danneggiate

2.3 Algoritmi per la trascrittomica spaziale

Una volta creata la library dei geni, i dati ottenuti vengono elaborati con algoritmi di analisi spaziale. Tra i più famosi figurano *Seurat*[13], *GraphST*[14] e *Giotto*[15].

2.3.1 Seurat

Seurat originariamente era un tool per l'analisi di dati di scRNA-seq, ma da recenti aggiornamenti possiede strumenti utili all'analisi di dati spaziali. Permette funzioni di normalizzazione, identificazione di HVGs e di SVGs, analisi multisezione ed altro. Offre anche funzioni per visualizzare sull'immagine tissutale l'espressione dei geni, cluster e l'integrazione fra slices, anche con opzioni per evidenziare contorni cellulari o centroidi.

In sintesi, Seurat, è un tool ben consolidato e ampiamente usato, con buone interfacce e integrazioni con l'ecosistema scRNA-seq. Tuttavia, non essendo nato per questo scopo, ma essendo stato adattato in seguito, può risultare meno potente di pipeline specializzate.

2.3.2 GraphST

GraphST è un pacchetto più recente, progettato specificamente per dati di trascrittomica spaziale, che sfrutta reti neurali e addestramento self-supervised per integrare informazione spaziale ed espressione genica. Questo algoritmo lavora attraverso l'utilizzo di grafi non diretti, in cui ogni nodo è uno spot diverso, e gli archi collegano gli spot vicini tra loro in base alle coordinate spaziali. Utilizza poi una rete neurale (Graph Neural Network) per apprendere rappresentazioni informative e discriminative negli spot e minimizzandone la distanza dove sono spazialmente adiacenti e viceversa.

Al contrario di Seurat, quindi, GraphST è stato progettato specificamente per dati spaziali, riuscendo ad offrire buone prestazioni rispetto ai competitor. Nonostante ciò, richiede diversa attenzione per la costruzione del grafo, ed avendo una rete neurale richiede più risorse computazionali e tempo per l'addestramento¹⁰ rispetto ad altre soluzioni.

2.3.3 Giotto

Giotto è un toolkit open-source scritto in R pensato per l'analisi integrata di dati spaziali, con una serie di moduli per clustering spaziale, rilevamento di

¹⁰Processo di allenamento di un modello per eseguire un compito specifico

domini e interazioni tra cellule. Costruisce internamente una “spatial neighborhood network” che connette spot vicini in base alle coordinate fisiche. Il grafo ottenuto viene poi utilizzato per tutte le analisi spaziali. Questo toolkit offre vari metodi di clustering: sia classici basati su espressione, come l’algoritmo k-means, e sia metodi che integrano la struttura spaziale, in particolare un modello basato su Hidden Markov Random Fields (HMRF) che dà vita a cluster spazialmente coerenti.

Riassumendo Giotto è un toolkit abbastanza completo con molti moduli, incluso il modello HMRF che dà una componente spaziale ben fondata per il clustering. Tuttavia non avendo una rete neurale, al contrario di GraphST, potrebbe non cogliere pattern spaziali complessi.

2.4 Limiti

Nonostante i grandi progressi, la trascrittomiche spaziale presenta ancora vari problemi che ne frenano l’adozione su larga scala, tra cui: costi elevati, bassa risoluzione spaziale, lunghi tempi di risposta e aree di cattura ridotte. Inoltre, come detto precedentemente, idealmente gli identificatori molecolari univoci (UMI) in uno spot misurano l’espressione specifica dello spot, ma, spesso, questo non avviene nella pratica a causa della contaminazione causata dal sanguinamento degli spot vicini. Questo fenomeno genera un artefatto chiamato spot swapping. Ignorare tale problematica può portare a risultati fuorvianti, come l’identificazione errata di SVGs o la sovrastima dell’espressione genica in regioni specifiche del tessuto.

Nonostante ci siano strumenti specializzati per la risoluzione delle problematiche sopracitate, come SpotClean[16] per rimuovere lo spot swapping, e iSCALE[17] per poter utilizzare tessuti di grosse dimensioni, non esiste ad oggi un algoritmo unico che possa risolvere tutti i problemi della TS. Vari benchmark e review scientifiche hanno portato alla stessa conclusione: occorre una pipeline modulare, che si possa adattare alle esigenze specifiche di ciascun tessuto.

La TS resta un campo molto recente, e nuove analisi, metodi e software, vengono pubblicati ogni mese, perciò non sono da escludere eventuali sviluppi futuri che miglioreranno tale problematica[18].

Capitolo 3

Nozioni di base

Prendendo in esame un tessuto qualsiasi, questo viene sezionato e diviso in celle più piccole, dette *spot*. Uno spot, quindi, non è altro che una posizione pre-definita su una griglia, con un *barcode*¹ che lo identifica. In genere ogni spot ha un diametro di circa 55 μm e con una distanza da spot a spot di circa 100 μm [19].

Possiamo definire l'insieme dei nostri spots nel seguente modo:

$$\mathcal{S} = \{\mathcal{S}_1, \mathcal{S}_2, \dots, \mathcal{S}_n\} \quad (3.1)$$

dove ogni $\mathcal{S}_i$ è uno spot.

Ogni spot, al suo interno, contiene più cellule. Per questo motivo, ogni spot viene associato ad un vettore di espressione genica che dà vita alla matrice $X \in \mathbb{R}^{n \times m}$ dove n è il numero di spot e m il numero di geni. Possiamo definire l'insieme dei nostri geni nel seguente modo:

$$\mathcal{G} = \{g_1, g_2, \dots, g_m\} \quad (3.2)$$

dove ogni g_i è un gene. Di conseguenza si può definire $\mathcal{S}_i \in \mathcal{G}^m$ come:

$$\mathcal{S}_i = \{g_1, g_2, \dots, g_m\} \quad (3.3)$$

La figura 3.1 mostra una rappresentazione grafica degli spot e dei geni all'interno di un tessuto. Ogni cella rappresenta uno spot, mentre ogni colore rappresenta un gene diverso². Si può notare che ogni spot $\mathcal{S}_i$, al suo interno, può contenere più geni. Inoltre, nella figura d'esempio, si hanno 36 spot diversi e 4 geni, ma nella realtà i dati sono differenti: gli spot possono arrivare a oltre 3000 celle e i geni possono superare i 30,000.

¹Una breve sequenza di DNA univoca per ogni spot

²Si noti che il colore non è rappresentativo della presenza o meno di quel gene in quello spot




Figura 3.1: Rappresentazione spots e geni

La figura 3.1, tuttavia, presenta una inesattezza in quanto gli spot non sono disposti su una matrice $n \times n$, bensì hanno una rappresentazione esagonale. Questo significa che, dato uno spot $\mathcal{S}_i$, questo presenterà sei spot adiacenti, tranne nei casi in cui gli spot sono localizzati ai bordi del tessuto.

Per poter trovare spazialmente uno spot $\mathcal{S}_i$, quindi, occorre assegnare una coordinata x e una coordinata y ad ogni spot, e, una volta creata una matrice $[\mathcal{S}_i, \langle x_i, y_i \rangle]$, dove $\langle x, y \rangle$ indicano le coordinate dello spot, è possibile trovare i 6 vicini attraverso un semplice calcolo. Inoltre, per sopperire ad eventuali spazi vuoti nel tessuto, viene calcolata la distanza euclidea tra gli spot, in modo da poter scartare gli spot che altrimenti verrebbero erroneamente segnati come vicini.

La figura 3.2 mostra una rappresentazione grafica degli spot in un tessuto, con le loro coordinate x e y . Lo spot preso in esempio, come riferimento, è lo spot con coordinate $x = 2, y = 3$.



Figura 3.2: Rappresentazione spaziale spots

3.1 Smoothing spaziale

Quando si entra in possesso di una library, contenente i barcode degli spot, le coordinate spaziali e i relativi metadati, non è consigliato avviare l'analisi dei dati fin da subito, questo perchè i dati di TS contengono anche rumore tecnico e biologico che può mascherare dei pattern in realtà utili, come ad esempio dei geni con profili irregolari. Occorre quindi prima di tutto ripulire e ridurre la complessità dei dati prima di poterli analizzare.

Uno dei primi step per poter minimizzare il rumore è applicare un *filtro di media* (Mean Filter), ovvero una tecnica per poter sostituire ogni elemento, con la media dei valori dei suoi vicini dato un raggio prestabilito[15]. Questo serve per poter ridurre il rumore locale ed evitare variazioni importanti.

Considerando un tessuto a due dimensioni, contenente $\mathcal{S}$ spots e $\mathcal{G}$ geni. Possiamo denotare con $y_{ij} \in \mathbb{R}$ il livello di espressione genica di un determinato gene g_i nello spot $\mathcal{S}_i$. Dalla definizione di matrice di espressione genica X definita precedentemente, possiamo ora definire $\hat{X}$ la matrice ottenuta come output dopo aver applicato la seguente operazione:

$$\hat{y}_{ij} = \sum_{s_k \in \mathcal{N}_r(s_j)} w_{jk} \cdot y_{ik} \quad (3.4)$$

dove $\mathcal{N}_r(s_j) = \{s_k \mid \|s_k - s_j\| \leq r, s_k \in \mathcal{S}\}$ con raggio $r \in \mathbb{R}$ denota i vicini dello spot s_j , e w_{jk} sono i pesi spaziali che soddisfano $\sum_k w_{jk} = 1$.

Per trovare i pesi spaziali poi, viene applicato il filtro di media:

$$w_{jk} = \frac{1}{|\mathcal{N}_r(s_j)|} \quad (3.5)$$

dove $\mathcal{N}_r(s_j)$ denota i vicini dello spot s_j entro il raggio r , e tutti i vicini contribuiscono in modo equivalente.

In alternativa al filtro di media è possibile utilizzare la *Gaussian Kernel Smoothing*[20] per calcolare i pesi spaziali. Prima si devono calcolare i pesi non normalizzati usando un Kernel Gaussiano:

$$\tilde{w}_{jk} = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{\|s_k - s_j\|^2}{2\sigma^2}\right) \quad (3.6)$$

dove σ controlla la portata spaziale di smoothing. Dopodichè andremo ad applicare una normalizzazione³ per ottenere i pesi finali:

$$w_{jk} = \frac{\tilde{w}_{jk}}{\sum_h \tilde{w}_{jh}} \quad (3.7)$$

garantendo che $\sum_k w_{jk} = 1$ per ogni spot s_j .




Figura 3.3: Dimostrazione di Smoothing Spaziale

La figura 3.3 dimostra come filtro di media attenua le variazioni locali, riducendo i valori e producendo una mappa più omogenea dove i picchi isolati di rumore risultano smussati.

Smoothing Spaziale a due fattori Un'altra variante allo smoothing visto sopra è lo *smoothing a due fattori*, che combina i vicini spaziali e la loro somiglianza trascrizionale, ovvero i pattern. Usando lo smoothing a due fattori, i dati smussati risultano essere più accurati nelle loro partizioni e interpretazioni biologiche rispetto all'utilizzo di operazioni a un fattore[21].

Dato $\mathcal{X}_i$ un vettore di espressione genica per uno spot i , la sua versione smussata $\mathcal{X}'_i$ può essere calcolata come segue:

³Dividere tutti i termini di un'espressione per uno stesso fattore in modo che l'espressione risultante abbia una certa norma uguale a 1.

$$\mathcal{X}'_i = (1 - \alpha) \mathcal{X}_i + \alpha \left(\beta \frac{\sum_{j \in N_s(i)} c_{ji}^s \mathcal{X}_j}{\sum_{k \in N_s(i)} c_{ki}^s} + (1 - \beta) \frac{\sum_{j \in N_p(i)} c_{ji}^p \mathcal{X}_j}{\sum_{k \in N_p(i)} c_{ki}^p} \right). \quad (3.8)$$

Nella equazione 3.8 ci sono due parametri, α e β . La prima regolarizza il rapporto tra l'espressione originale e quella corretta, evitando che l'espressione dello spot in esame risulti eccessivamente smussata. β invece modula il peso relativo dello smussamento basato sulla vicinanza spaziale rispetto a quello basato sui pattern. $N_s(i)$ e $N_p(i)$ indicano, rispettivamente, i vicini spaziali e i pattern nello spot i . c_{ji}^p e c_{ji}^s indicano, rispettivamente, il contributo spaziale e quello di pattern dello spot j vicino allo spot in oggetto i .

3.2 Formato dei dati

I dati del campione di tessuto fornitoci sono in formato *10x Visium*, una piattaforma di trascrittomica spaziale che misura l'espressione genica su sezioni di tessuto, mantenendo per ogni misura la posizione spaziale. La cattura avviene su spot barcodati stampati su una slide. Il programma che processa i dati in modo da mappare i barcode con la loro posizione spaziale viene chiamato *Space Ranger* e produce la matrice *Features* $\times$ *Barcodes*, dove con *Features* si intendono i geni, e con *Barcodes* i vari spot; Ogni spot raccoglie RNA da più cellule e i conteggi vengono poi mappati sull'immagine.

I file 10x Visium sono in formato `.h5`, un file specifico pronto per essere elaborato da *ScanPy* una libreria Python⁴ open-source⁵ progettata per l'analisi di dati di trascrittomica. Scanpy infatti offre la funzione `sc.read_visium()` per importare direttamente le cartelle di output di Space Ranger.

Prendendo il file `.h5` e traducendolo in un file `.tsv` (Tab-Separated Values) si può osservare una struttura di questo tipo:

Tabella 3.1: Estratto metadati spot (dataset 1.DLPFC).

Barcode	Row	Col	Cluster	sum_Gene
AAACAAGTATCTCCCA-1	1	3	7	3586
AAACAATCTACTAGCA-1	1	27	4	1150
AAACACCAATAACTGC-1	1	59	8	1960

barcode: identificatore dello spot; **sample_name:** nome del campione;

row, col: coordinate dello spot nella griglia;

Cluster: cluster di appartenenza; **sum_gene:** numero totale di geni rilevati.

⁴Linguaggio di programmazione di alto livello, interpretato e open source

⁵Codice sorgente libero

La tabella 3.1 è solo una sezione di cosa contiene davvero il file `.h5`, nella realtà sono presenti svariati gigabyte di dati.

Oltre ai file sopracitati viene fornita anche una cartella chiama `spatial` contenente immagini ad alta e bassa definizione del tessuto, e il file delle posizioni degli spot chiamato `tissue_positions.csv`



Figura 3.4: File che contiene la foto del tessuto: `tissue_hires_image.png`

3.3 Scanpy

Scanpy è un toolkit in Python per l'analisi di dati di espressione genica a singola cellula, progettato per lavorare anche con dataset molto estesi e per integrarsi con l'ecosistema Python. Include metodi per il pre-processing, come filtri su cellule e geni, normalizzazione, identificazione degli HVGs e clustering.

Scanpy fornisce inoltre funzioni con velocità elevate che rendono l'analisi di data set con più di un milione di cellule e interrogazioni real time nell'ordine di secondi per data set con circa 100,000 cellule. Questa moltitudine di funzioni,

assieme ad velocità non indifferente, ne hanno favorito l'adozione in molti ambiti di ricerca.[22]

Dal punto di vista della manutenibilità invece, Scanpy è sviluppato nell'ambito del progetto *scverse*, che coordina strumenti fondamentali per l'analisi omica in Python. Questo garantisce linee guida comuni, interoperabilità tra pacchetti e una documentazione unificata, elementi cruciali in contesti accademici e clinici dove la tracciabilità delle analisi è essenziale.[23]

Le funzioni della libreria sono organizzate per famiglie:

- `sc.pp.*` riguarda le varie funzioni per il pre-processing.
- `sc.tl.*` serve per gli strumenti analitici, come clustering o creazione di grafi.
- `sc.pl.*` infine riguarda le varie funzioni usate per la visualizzazione, con cui è possibile stampare a video delle immagini.

Per la trascrittomica spaziale, Scanpy offre un'integrazione naturale con i dati 10x Visium tramite `scanpy.read_visium()`, che carica non solo la matrice di espressione ma anche immagini e coordinate degli spot. la funzione ha la seguente firma:

```
scanpy.read_visium(  
    path,  
    genome = None,  
    count_file = 'filtered_feature_bc_matrix.h5',  
    library_id = None,  
    load_images = True,  
    source_image_path = None  
)
```

Gli argomenti della funzione sono i seguenti:

- **path**: Percorso alla cartella radice che contiene l'output Visium, ovvero il file `.h5` e la sottocartella `spatial/`.
- **genome**: Opzionale, è l'identificatore del genoma che si vuole filtrare, se presente nei metadati 10x.
- **count_file**: Nome del file di 10x Visium contenente i vari dati. Deve essere presente nella cartella inserita in **path**. Di default ha come nome (`filtered_feature_bc_matrix.h5` per default).
- **library_id**: Opzionale, è l'identificativo della libreria Visium. Risulta utile quando occorre concatenare più librerie.

- `load_images`: Se `True`, carica le immagini del tessuto.
- `source_image_path`: Opzionale, è il percorso alternativo da cui leggere le immagini se non si trovano in `spatial/`.

La funzione restituisce un oggetto `AnnData`, una struttura dati che accoppia in modo coerente la matrice di espressione con annotazioni su spot e geni, oltre che a campi dedicati per grafi e metadati. `anndata.X` contiene la matrice *Features* $\times$ *Barcodes*, `anndata.obs` da *Observations* contiene tutti e solo i barcodes degli spot, mentre `anndata.vars` da *Variables* contiene tutti e solo i geni misurati, con nome, id e tipo. Gli oggetti `AnnData` si possono salvare tramite la funzione `anndata.write_h5ad()` e i file così creati hanno estensione `.h5ad`.

La funzione sopracitata ha la seguente firma:

```
anndata.write_h5ad(  
    filename,  
    compression = hdf5plugin.FILTERS["zstd"]  
)
```

Con come argomenti:

- `filename`: Il nome del file che si vuole salvare con estensione `.h5ad`.
- `compression`: Opzionale, metodi alternativi di compressione del file.

Un esempio completo di un programma scritto in linguaggio Python con lettura dei dati 10x Visium attraverso Scanpy e relativo salvataggio di `AnnData` in formato `.h5ad` è il seguente:

```
1 import scanpy as sc  
2  
3 def load_data():  
4  
5     adata_gene_expression = sc.read_visium("1.DLPFC  
6     /151673", count_file="filtered_feature_bc_matrix.h5",  
7     load_images=True)  
8  
9     return adata_gene_expression  
10  
11 annData = load_data()  
12  
13 annData.write_h5ad(filename="processed_adata")
```


Bibliografia

- [1] Istituto dell'Enciclopedia Italiana Treccani. Informatica, n.d.
- [2] B. Pascal and C. Voza. *Pensieri*. Guaraldi, 1995.
- [3] Simon Singh and Stefano Galli. *Codici & segreti*. Rizzoli Milano, 1999.
- [4] Eric W Sayers, Jeffrey Beck, Evan E Bolton, Devon Bourexis, James R Brister, Kathi Canese, Donald C Comeau, Kathryn Funk, Sunghwan Kim, William Klimke, et al. Database resources of the national center for biotechnology information. *Nucleic acids research*, 49(D1):D10–D17, 2021.
- [5] David L. Nelson and Michael M. Cox. *I principi di biochimica di Lehninger*. Zanichelli, 2018.
- [6] Manuela Helmer Citterich, F Ferré, G Pavesi, C Romualdi, and G Pesole. *Fondamenti di bioinformatica*. Zanichelli, 2018.
- [7] National Human Genome Research Institute. Epigenomics fact sheet, 2020.
- [8] Cameron G Williams, Hyun Jae Lee, Takahiro Asatsuma, Roser Vento-Tormo, and Ashraful Haque. An introduction to spatial transcriptomics for biomedical research. *Genome medicine*, 14(1):68, 2022.
- [9] Xuanwei Chen, Qinghua Ran, Junjie Tang, Zihao Chen, Siyuan Huang, Xingjie Shi, and Ruibin Xi. Benchmarking algorithms for spatially variable gene identification in spatial transcriptomics. *Bioinformatics*, 41(4):btaf131, 03 2025.
- [10] B. Li, W. Zhang, C. Guo, H. Xu, L. Li, M. Fang, Y. Hu, X. Zhang, X. Yao, M. Tang, et al. Benchmarking spatial and single-cell transcriptomics integration methods for transcript distribution prediction and cell type deconvolution. *Nature Methods*, 19:662–670, 2022.

- [11] Coral Fustero-Torre, María José Jiménez-Santos, Santiago García-Martín, Carlos Carretero-Puche, Luis García-Jimeno, Vadym Ivanchuk, Tomás Di Domenico, Gonzalo Gómez-López, and Fátima Al-Shahrour. Beyond-cell: targeting cancer therapeutic heterogeneity in single-cell rna-seq data. *Genome Medicine*, 13(1):187, 2021.
- [12] Yang Jin, Yuanli Zuo, Gang Li, Wenrong Liu, Yitong Pan, Ting Fan, Xin Fu, Xiaojun Yao, and Yong Peng. Advances in spatial transcriptomics and its applications in cancer research. *Molecular Cancer*, 23(1):129, Jun 2024.
- [13] Rahul Satija. Analysis, visualization, and integration of spatial datasets with Seurat — satijalab.org. https://satijalab.org/seurat/articles/spatial_vignette.html.
- [14] Y. Long, K. S. Ang, M. Li, K. L. K. Chong, R. Sethi, C. Zhong, H. Xu, Z. Ong, K. Sachaphibulkij, A. Chen, L. Zeng, H. Fu, M. Wu, L. H. K. Lim, L. Liu, and J. Chen. Spatially informed clustering, integration, and deconvolution of spatial transcriptomics with graphst. *Nature Communications*, 14(1):1155, Mar 2023.
- [15] Ruben Dries, Qian Zhu, Rui Dong, Chee-Huat Linus Eng, Huipeng Li, Kan Liu, Yuntian Fu, Tianxiao Zhao, Arpan Sarkar, Feng Bao, Rani E. George, Nico Pierson, Long Cai, and Guo-Cheng Yuan. Giotto: a toolbox for integrative analysis and visualization of spatial expression data. *Genome Biology*, 22(1):78, Mar 2021.
- [16] Zhenhao Ni, Abhinav Prasad, Shanshan Chen, et al. Spotclean adjusts for spot swapping in spatial transcriptomics data. *Nature Communications*, 13:2971, 2022.
- [17] Andreas Schroeder, Maximilian L. Loth, Chao Luo, et al. Scaling up spatial transcriptomics for large-sized tissues: uncovering cellular-level tissue architecture beyond conventional platforms with iscale. *Nature Methods*, 22:1911–1922, 2025.
- [18] J Gillespie, M Pietrzak, MA Song, and D Chung. A meta-review of spatial transcriptomics analysis software. *Cells*, 14(14):1060, Jul 2025.
- [19] What is the spatial resolution and configuration of the capture area of the Visium v1 Gene Expression Slide? kb.10xgenomics.com. [Accessed 06-10-2025].

- [20] Tongxuan Lv, Ying Zhang, Mei Li, Qiang Kang, Shuangfang Fang, Yong Zhang, Susanne Brix, and Xun Xu. Eags: efficient and adaptive gaussian smoothing applied to high-resolved spatial transcriptomics. *GigaScience*, 13:giad097, 02 2024.
- [21] Yusong Liu, Tongxin Wang, Ben Duggan, Michael Sharpnack, Kun Huang, Jie Zhang, Xiufen Ye, and Travis S Johnson. Spcs: a spatial and pattern combined smoothing method for spatial transcriptomic expression. *Briefings in Bioinformatics*, 23(3):bbac116, 04 2022.
- [22] F. Alexander Wolf, Philipp Angerer, and Fabian J. Theis. Scanpy: large-scale single-cell gene expression data analysis. *Genome Biology*, 19(1):15, 2018.
- [23] Isaac Virshup, Danila Bredikhin, Lukas Heumos, Giovanni Palla, Gregor Sturm, Adam Gayoso, Ilia Kats, Mikaela Koutrouli, Philipp Angerer, Volker Bergen, Pierre Boyeau, Maren Büttner, Gokcen Eraslan, David Fischer, Max Frank, Justin Hong, Michal Klein, Marius Lange, Romain Lopez, Mohammad Lotfollahi, Malte D. Luecken, Fidel Ramirez, Jeffrey Regier, Sergei Rybakov, Anna C. Schaar, Valeh Valiollah Pour Amiri, Philipp Weiler, Galen Xing, Bonnie Berger, Dana Pe’er, Aviv Regev, Sarah A. Teichmann, Francesca Finotello, F. Alexander Wolf, Nir Yosef, Oliver Stegle, Fabian J. Theis, and Scverse Community. The scverse project provides a computational ecosystem for single-cell omics data analysis. *Nature Biotechnology*, 41(5):604–606, May 2023.

