



UNIVERSITÀ DI PARMA

DIPARTIMENTO DI SCIENZE MATEMATICHE, FISICHE E INFORMATICHE

Corso di Laurea Triennale in Informatica

Una metodologia computazionale per il riconoscimento di clustering alternativi nella trascrittomica spaziale

*A computational methodology for the recognition of
alternative clustering in spatial transcriptomics*

CANDIDATO:
Matteo Cerinelli

RELATORE:
Prof. Vincenzo Bonnici

MATRICOLA:
294907

Indice

1	Introduzione	9
2	Conclusione	11
	Bibliografia	13

Elenco delle figure

Elenco degli algoritmi

Elenco delle tabelle

Capitolo 1

Introduzione

Negli ultimi anni la *trascrittomica spaziale* (TS) ha rappresentato una delle innovazioni più significative nel campo della biologia molecolare e della bioinformatica. A differenza delle tecniche di trascrittomica tradizionali, che misurano i livelli di espressione genica senza informazioni di posizione in quanto le cellule devono essere estratte dal tessuto, la trascrittomica spaziale consente di mappare l'attività dei geni direttamente nel contesto del tessuto senza bisogno alcuno di doverle rimuovere. Questo approccio fornisce una visione bidimensionale dell'espressione genica, permettendo di studiare non solo quali geni sono attivi, ma anche la loro posizione spaziale.

La possibilità di associare informazione spaziale all'espressione ha aperto nuove prospettive nello studio dei processi biologici complessi, come lo sviluppo embrionale, l'organizzazione dei tessuti e la progressione di patologie come i tumori. Tuttavia, l'analisi di questo tipo di dati presenta notevoli sfide computazionali: la quantità di dati da analizzare è elevata e le relazioni spaziali tra geni sono intricate, e l'analisi dei cluster spaziali non sempre scova tutti i possibili pattern, spesso scambiando rumore per dati utili o viceversa. Da qui nasce la necessità di sviluppare strumenti e algoritmi in grado di integrare informazione geometrica, topologica di espressione al fine di trovare cluster alternativi.

Date queste premesse si sviluppa il lavoro presentato in questa tesi, il cui obiettivo principale è stato quello di progettare e realizzare una pipeline computazionale per l'identificazione e la classificazione delle relazioni spaziali tra geni in un dataset 10x Visium. Partendo dai dati di espressione e dalle coordinate spaziali degli *spot*, è stata costruita una lista degli spot vicini tramite l'algoritmo dei *Nearest Neighbors* (k-NN), in modo da avere le connessioni spaziali tra i vari spot del tessuto. Successivamente, ogni gene è stato suddiviso in *sottogeni*, regioni locali di espressione contigua, mediante l'individuazione delle *componenti connesse* partendo dalle maschere binarie di espressione genica.

Questo passaggio ha consentito di confrontare i sottogruppi tra loro e valutare diverse tipologie di rapporto spaziale: sovrapposizione, contenimento o semplice vicinanza.

Attraverso la creazione di un algoritmo di classificazione basato su criteri quantitativi e topologici, sono state introdotte cinque categorie di relazione: DISGIUNTI, IN_COSTA, A_CONTENUTO, B_CONTENUTO e VICINI. Le informazioni ottenute sono state poi adattate in file adatti ad essere analizzati da *Gephi*, software open-source dedicato all'analisi di grafi complessi, al fine di individuare pattern spaziali di interazione tra geni che, in forma tabellare, sarebbero stati difficilmente riconoscibili. In particolare, lo studio del grafo dei VICINI ha rivelato la presenza di cluster fortemente connessi, suggerendo regioni di possibile co-localizzazione genica e relazioni funzionali potenzialmente rilevanti.

Per verificare la consistenza di tali osservazioni, i risultati grafici sono stati presi e studiati con un'analisi di *clustering* condotta tramite il modello *Graph-ST* e successivamente raffinata con *Mclust*. L'obiettivo di questa seconda fase era valutare se le relazioni spaziali individuate tra geni corrispondessero anche a pattern nei dati di espressione. Sebbene non siano emersi cluster alternativi significativi, l'esperimento ha permesso di validare la correttezza del metodo proposto, mostrando che la pipeline è in grado di analizzare in modo coerente e riproducibile la distribuzione spaziale dei geni.

In sintesi, questa tesi propone un approccio completo e modulare per l'analisi della trascrittomica spaziale, integrando strumenti di analisi dei grafi, algoritmi di clustering e visualizzazione interattiva. Il lavoro si inserisce nel contesto più ampio della bioinformatica computazionale e contribuisce a definire una base metodologica utile per l'esplorazione di pattern spaziali di espressione genica, offrendo spunti concreti per futuri sviluppi, sia sul piano tecnico che biologico.

Capitolo 2

Conclusione

Il lavoro svolto in questa tesi ha avuto come obiettivo la progettazione e l'implementazione di una metodologia computazionale per lo studio e il riconoscimento di potenziali *clustering alternativi* nei dati di trascrittoma spaziale.

L'intero processo è stato sviluppato in ambiente Python, integrando librerie come `Scanpy`, `sklearn` e strumenti per l'analisi grafica e statistica, fino a includere modelli avanzati come *GraphST* e *Mclust*. In particolare, la pipeline ha previsto:

- la costruzione di una mappa cartesiana degli *spot* e la definizione della lista degli spot vicini mediante l'algoritmo dei *Nearest Neighbors*;
- la suddivisione dei geni in sottogeni attraverso l'individuazione delle componenti connesse via *Breadth-First Search*;
- il calcolo dei rapporti spaziali tra sottogeni, classificati in cinque categorie (DISGIUNTI, IN_COSTA, A_CONTENUTO, B_CONTENUTO, VICINI);
- la rappresentazione dei rapporti tramite un grafo esportato e visualizzato in *Gephi*, utile per l'analisi visiva dei pattern e delle connessioni tra geni;

L'analisi del grafo dei geni VICINI ha rivelato la presenza di cluster ben distinti: un macro-cluster centrale, caratterizzato da un'elevata connettività, e uno secondario di dimensioni ridotte, in cui un singolo gene fungeva da nodo centrale. Questa osservazione ha confermato che i rapporti di vicinanza possono essere interpretati come indicatori di co-localizzazione spaziale tra geni, suggerendo possibili interazioni locali o domini funzionali condivisi.

Per valutare se tali correlazioni spaziali corrispondessero anche a una reale struttura trascrittoma interna al tessuto, si è proceduto con un'analisi di

clustering basata su *GraphST* e *Mclust*. Nonostante la solidità metodologica dell'approccio, i risultati non hanno mostrato l'emergere di cluster alternativi significativi. Questo esito suggerisce che la vicinanza spaziale tra geni non implica necessariamente una correlazione diretta di espressione, ma può riflettere fenomeni locali di prossimità o di contatto marginale.

Il lavoro ha comunque raggiunto l'obiettivo di costruire una pipeline modulare, robusta e replicabile per l'analisi computazionale di dati di trascrittoma spaziale, aprendo la strada a possibili sviluppi futuri. Tra le direzioni di approfondimento più promettenti si segnalano:

- l'integrazione con algoritmi di ricerca per scovare in autonomia potenziali nuovi pattern nel grafo Gephi;
- la creazione di un algoritmo di classificazione migliore basato sulla struttura delle maschere binarie;

In conclusione, la metodologia proposta rappresenta un contributo utile per l'esplorazione delle relazioni spaziali tra geni nei dati di trascrittoma. Pur non avendo individuato nuovi cluster, il lavoro ha permesso di consolidare una base analitica solida e riproducibile, capace di essere estesa e adattata a futuri studi in ambito bioinformatico e computazionale. La trascrittoma spaziale resta un campo in rapida evoluzione, e strumenti di analisi come quello sviluppato in questa tesi potranno costituire un supporto prezioso per comprendere meglio la complessità dei tessuti e l'organizzazione spaziale dell'espressione genica.

Bibliografia

