



UNIVERSITÀ DI PARMA

DIPARTIMENTO DI SCIENZE MATEMATICHE, FISICHE E INFORMATICHE

Corso di Laurea Triennale in Informatica

Trascrittomica spaziale

CANDIDATO:
Matteo Cerinelli

RELATORE:
Prof. Vincenzo Bonnici

MATRICOLA:
294907

Indice

1	Introduzione	3
2	Nozioni di base	5
2.1	Gene	5
2.1.1	Epigenoma	6
2.1.2	Trascrittoma	7
2.2	Trascrittomica spaziale	7
2.2.1	Dati e metodi	8
2.3	Algoritmi per la trascrittomica spaziale	10
2.3.1	Seurat	10
2.3.2	GraphST	11
2.3.3	Giotto	11
	Bibliografia	13

Capitolo 1

Introduzione

L'introduzione deve contenere un riassunto del lavoro di Tesi. In particolare bisogna esprimere chiaramente e molto sinteticamente: contesto dello studio, motivazioni, contributo e conclusioni. Bisogna quindi fare un sommario dello studio ad alto livello, fornendo le intuizioni senza ricadere in dettagli tecnici. Anche lo stile dovrebbe essere più discorsivo rispetto alle parti tecniche della tesi.

Capitolo 2

Nozioni di base

Dall'alba dei tempi tutto ciò che circonda l'uomo è stato fonte di curiosità e studio. Partendo dall'interesse di tutti i vari aspetti riguardanti l'essere umano e gli organismi viventi, con cui ci relazioniamo quotidianamente, si è sviluppata la branca della biologia

L'informatica, invece, la branca della scienza che si occupa dello studio e dell'elaborazione delle informazioni, è stata fin da sempre utilizzata come strumento per migliorare la qualità della vita dell'uomo[4]. Dalla prima calcolatrice meccanica, la *Pascalina*, inventata da Blaise Pascal nel 1644[7], alla *Macchina di Turing*, ideata da Alan Turing nel 1943[10], fino ai moderni computer quantistici, l'informatica ha sempre avuto un ruolo fondamentale nell'evoluzione della società umana.

Lo sviluppo di entrambe queste discipline col passare degli anni ha portato ad un'innovazione: la *bioinformatica*. La bioinformatica nasce dalla combinazione delle due materie prima elencate in quanto gli scienziati manifestavano sempre più l'esigenza di gestire i dati rilevati dalla biologia molecolare, questo perchè, spesso, i dati superano le decine di gigabyte e serviva un modo per poter interpretare più facilmente i campioni raccolti. Oggi la gran parte delle informazioni bioinformatiche possono essere reperite sul *National Center of Biotechnology Information (NCBI)* che fornisce anche dati gratuite e strumenti per la ricerca in biologia molecolare e bioinformatica.[9]

2.1 Gene

Ogni organismo, eucariote o procariote, pluricellulare o unicellulare che sia, presenta una molecola fondamentale che contiene tutte le informazioni necessarie per costituire l'organismo, tale molecola è il DNA (acido desossiribonucleico). Il DNA è composto da subunità, chiamate nucleotidi¹, contenenti: un

¹Il nucleotide è l'unità di base che forma DNA e RNA

gruppo fosfato, uno zucchero pentoso e una base azotata. Una specifica sequenza di DNA forma un gene e, l'insieme di tutti i geni, genera il genoma che, oltre a racchiudere le informazioni genetiche, presenta anche le parti del DNA che non codificano proteine². Circa il 30% del DNA nel genoma umano si trova negli esoni e negli introni. I primi, gli esoni, sono sequenze che codificano gli aminoacidi, i quali, vengono espressi in proteine, i secondi, gli introni, invece non codificano nessuna proteina. Al giorno d'oggi sappiamo che il genoma umano presenta circa 20000 geni che codificano proteine. Con il passare degli anni sono stati sequenziati molti genomi, sia di microrganismi che di animali, questo perché, l'interesse degli scienziati è quello di andare definire i processi evolutivi degli esseri viventi, ma, per ottenere dei risultati, è indispensabile andare a comparare numerosi genomi di organismi differenti.

La branca della bioinformatica è molto ampia, per questo, noi ci interesseremo principalmente del genoma. La bioinformatica ha un ruolo fondamentale negli studi della struttura del genoma, per esempio, nell'assemblaggio e annotazione di genomi, o nella caratterizzazione del profilo di espressione genica, generando informazioni cruciali per orientare i successivi studi di genomica funzionale, i quali, si avvalgono di una grande varietà di tecniche sperimentali[2]

Possiamo quindi dire che tutte le cellule di un organismo hanno lo stesso genoma, ma possono presentare epigenomi e trascrittomi molto diversi.

2.1.1 Epigenoma

L'*epigenoma* è una moltitudine di composti chimici e preteine che regolano il genoma su cosa fare senza cambiare la sequenza del DNA. Esso contiene le varie istruzioni per poter costruire le proteine necessarie per svolgere le diverse funzioni della cellula. L'epigenoma, poi, può attaccarsi al DNA e impartire diversi comandi, tra cui l'attivazione o la disattivazione di geni, o il controllo della produzione di determinate proteine all'interno della cellula stessa.

Un essere umano possiede trilioni di cellule distribuite nei tessuti: muscolare, nervoso e osseo e, ciascuna delle cellule che compongono i tessuti, presenta essenzialmente lo stesso genoma all'interno del nucleo³. Le differenze tra le cellule sono determinate da come e quando diversi gruppi di geni vengono attivati o disattivati in vari tipi di cellule. Se prendiamo, ad esempio, in esame le cellule specializzate nell'occhio, queste attivano specifici geni che producono proteine in grado di rilevare la luce, mentre le cellule specializzate nei globuli

²Le proteine sono macromolecole che si formano partendo dal DNA e che vanno a costituire i tessuti.

³il nucleo è una struttura subcellulare, presente negli eucarioti, che contiene il DNA.

rossi producono proteine che trasportano l'ossigeno dall'aria al resto del corpo. L'epigenoma quindi controlla molti di questi cambiamenti nel genoma.[6]

2.1.2 Trascrittoma

Il DNA, non viene utilizzato direttamente per costruire le proteine: prima deve essere trascritto in RNA. Questo processo prende il nome di trascrizione e produce diversi tipi di RNA. Il *trascrittoma* rappresenta l'insieme di tutte le molecole di RNA presenti in una cellula in un dato momento.

L'RNA principale è l'RNA messaggero (mRNA) il quale trasporta le istruzioni dai geni ai ribosomi dove verranno generate le proteine mediante l'attività di sintesi proteica. Nei ribosomi, la sequenza di basi dell'mRNA viene letta e tradotta in catene di amminoacidi. Accanto all'mRNA, esistono anche altri tipi di RNA che non codificano proteine ma che svolgono funzioni regolatorie o strutturali, contribuendo a controllare l'attività dei geni e l'organizzazione della cellula. Poiché ogni cellula del corpo umano possiede lo stesso patrimonio genetico, ciò che la distingue dalle altre non è il genoma ma l'insieme dei geni che vengono attivati o silenziati. Questo insieme di trascrizioni geniche costituisce il trascrittoma, e varia notevolmente da cellula a cellula e da tessuto a tessuto. Ad esempio, le cellule muscolari esprimono geni che producono proteine contrattili, mentre le cellule nervose attivano geni che permettono la trasmissione dei segnali elettrici.

Il trascrittoma quindi è lo specchio dell'attività del genoma: mostra quali geni sono effettivamente in funzione in un determinato momento e fornisce informazioni preziose sull'identità, lo stato e la salute delle cellule.[6]

2.2 Trascrittomica spaziale

Come detto in precedenza, il trascrittoma rappresenta l'insieme di tutte le molecole di RNA presenti in una cellula in un dato momento. La trascrittomica a singola cellula (scRNA-seq) è diventata essenziale per la ricerca biomedica nell'ultimo decennio, in particolare nello sviluppo della biologia, cancro, immunologia e neuroscienze.

La maggior parte dei protocolli scRNA-seq disponibili in commercio richiedono che le cellule siano recuperate intatte e vitali dai tessuti. Ciò ha precluso lo studio di molti tipi cellulari e ha in gran parte distrutto il contesto spaziale che altrimenti avrebbe potuto informare le analisi dell'identità e della funzione cellulare. Oggi, un numero crescente di piattaforme disponibili in commercio, consente di mappare l'espressione dell'RNA direttamente sulla struttura del tessuto, mantenendo l'informazione di posizione di ciascun segnale: questo approccio, noto come *trascrittomica spaziale (ST)*, produce dati ad alta

dimensionalità utili a descrivere l'organizzazione cellulare e i processi biologici direttamente nel tessuto, preservandone la posizione.[11]

Una sfida fondamentale nella TS è l'identificazione degli *Spatially Variable Genes (SVGs)*. Questi ultimi sono geni la cui espressione varia in modo dipendente dalla posizione nello spazio del tessuto. Analizzando lo spazio è possibile scovare pattern non casuali di espressione genica. Identificarli è cruciale nelle analisi di TS perché rivela domini tissutali, le quali sono nicchie cellulari e transizioni; In più facilita l'annotazione⁴ e quindi il clustering.[1] Oltre agli SVGs esistono anche gli *Highly Variable Genes (HVGs)*, geni, che presentano una variabilità di espressione molto superiore a quanto atteso, nonostante ciò non sono in grado di fornire informazioni spaziali rilevanti.




Figura 2.1: HVGs e SVGs a confronto

La figura 2.1 presenta un confronto tra HVGs e SVp alcuna iGs dato lo stesso Dataset. Si noti come gli HVGs non possiedono alcuna informazione spaziale, in quanto, non presentano alcun tipo di pattern; Gli SVGs, al contrario, mostrano una chiara suddivisione in cluster.

2.2.1 Dati e metodi

Prendendo in esame un tessuto qualsiasi, questo viene sezionato e diviso in celle più piccole, dette *spot*. Uno spot, quindi, non è altro che una posizione pre-definita su una griglia, con un *barcode*⁵ che lo identifica. Possiamo definire

⁴L'assegnazione di etichette biologiche a cluster o spot

⁵Una breve sequenza di DNA univoca per ogni spot

l'insieme dei nostri spots nel seguente modo: $\mathcal{S} = \{\mathcal{S}_1, \mathcal{S}_2, \dots, \mathcal{S}_n\}$ dove ogni $\mathcal{S}_i$ è uno spot.

Ogni spot, al suo interno, contiene più cellule. Per questo motivo, ogni spot viene associato ad un vettore di espressione genica che dà vita alla matrice $X \in \mathbb{R}^{n \times m}$ dove n è il numero di spot e m il numero di geni. Possiamo definire l'insieme dei nostri geni nel seguente modo: $\mathcal{G} = \{g_1, g_2, \dots, g_m\}$ dove ogni g_i è un gene. Di conseguenza si può definire $\mathcal{S}_i \in \mathcal{G}^m$ come $\mathcal{S}_i = \{g_1, g_2, \dots, g_m\}$




Figura 2.2: Rappresentazione spots e geni

La figura 2.2 mostra una rappresentazione grafica degli spot e dei geni all'interno di un tessuto. Ogni cella rappresenta uno spot, mentre ogni colore rappresenta un gene diverso⁶. Si può notare che ogni spot $\mathcal{S}_i$, al suo interno, può contenere più geni. Inoltre, nella figura d'esempio, si hanno 36 spot diversi e 4 geni, ma nella realtà i dati sono differenti: gli spot possono arrivare a oltre 3000 celle e i geni possono superare i 30,000.

L'immagine 2.2, tuttavia, presenta una inesattezza in quanto gli spot non sono disposti su una matrice $n \times n$, bensì hanno una rappresentazione esagonale. Questo significa che, dato uno spot $\mathcal{S}_i$, questo presenterà sei spot adiacenti, tranne nei casi in cui gli spot sono localizzati ai bordi del tessuto.

⁶Si noti che il colore non è rappresentativo della presenza o meno di quel gene in quello spot

Per poter trovare spazialmente uno spot $\mathcal{S}_i$, quindi, occorre assegnare una coordinata x e una coordinata y ad ogni spot, e, una volta creata una matrice $[\mathcal{S}_i, \langle x_i, y_i \rangle]$, dove $\langle x, y \rangle$ indicano le coordinate dello spot, è possibile trovare i 6 vicini attraverso un semplice calcolo. Inoltre, per sopperire ad eventuali spazi vuoti nel tessuto, viene calcolata la distanza euclidea tra gli spot, in modo da poter scartare gli spot che altrimenti verrebbero erroneamente segnati come vicini.

La figura 2.3 mostra una rappresentazione grafica degli spot in un tessuto, con le loro coordinate x e y . Lo spot preso in esempio, come riferimento, è lo spot con coordinate $x = 2, y = 3$.




Figura 2.3: Rappresentazione spaziale spots

2.3 Algoritmi per la trascrittomiche spaziale

Esistono già diversi algoritmi per la trascrittomiche spaziale, tra cui *Seurat*[8], *GraphST*[5] e *Giotto*[3].

2.3.1 Seurat

Seurat originariamente era un tool per l'analisi di dati di scRNA-seq, ma ha da recenti aggiornamenti ha strumenti l'analisi di dati spaziali. Permette funzioni di normalizzazione, identificazione di HVGs e di SVGs, analisi multisezione ed altro. Offre anche unzioni per visualizzare sull'immagine tissutale l'espressione dei geni, cluster, l'integrazione fra slices, anche con opzioni che visualizzano contorni cellulari o centroidi.

In sintesi, Seurat, è un tool ben consolidato e ampiamente usato, con buone interfacce e integrazione con l'ecosistema scRNA-seq. Tuttavia, non essendo

nato per questo scopo, ma essendo stato adattato, può risultare meno potente di pipeline specializzate per evidenziare domini spaziali o interazioni locali.

2.3.2 GraphST

GraphST è un metodo più recente, progettato specificamente per dati di trascrittomica spaziale, che sfrutta reti neurali e addestramento self-supervised per integrare informazione spaziale ed espressione genica. Lavora attraverso l'utilizzo di grafi non diretti, in cui ogni nodo è uno spot diverso, e gli archi collegano gli spot vicini tra loro (in base alle coordinate spaziali). Utilizza poi la rete neurale (Graph Neural Network) per apprendere rappresentazioni informative e discriminative negli spot e minimizzandone la distanza dove sono spazialmente adiacenti e viceversa.

Al contrario di Seurat, quindi, GraphST è stato progettato specificamente per dati spaziali, riuscendo ad offrire buone prestazioni rispetto ai competitor. Tuttavia richiede diversa attenzione per la costruzione del grafo, ed avendo una rete neurale richiede più risorse computazionali e tempo per l'addestramento.

2.3.3 Giotto

Giotto è un toolkit open-source scritto in R pensato per l'analisi integrata di dati spaziali, con una serie di moduli per clustering spaziale, rilevamento di domini e interazioni tra cellule. Costruisce internamente una “spatial neighborhood network” che connette spot vicini in base alle coordinate fisiche. Il grafo così ottenuto viene poi utilizzato per tutte le analisi spaziali. Offre vari metodi di clustering: sia metodi classici basati su espressione (k-means, gerarchico) e sia metodi che integrano la struttura spaziale, in particolare un modello basato su Hidden Markov Random Fields (HMRF) che incoraggia cluster spazialmente coerenti.

In sostanza Giotto è un toolkit abbastanza completo con molti moduli, incluso il modello HMRF che dà una componente spaziale ben fondata per il clustering. Tuttavia non avendo una rete neurale, al contrario di GraphST, potrebbe non cogliere pattern spaziali complessi.

Bibliografia

- [1] Xuanwei Chen, Qinghua Ran, Junjie Tang, Zihao Chen, Siyuan Huang, Xingjie Shi, and Ruibin Xi. Benchmarking algorithms for spatially variable gene identification in spatial transcriptomics. *Bioinformatics*, 41(4):btaf131, 03 2025.
- [2] Manuela Helmer Citterich, F Ferré, G Pavesi, C Romualdi, and G Pesole. *Fondamenti di bioinformatica*. Zanichelli, 2018.
- [3] Ruben Dries, Qian Zhu, Rui Dong, Chee-Huat Linus Eng, Huipeng Li, Kan Liu, Yuntian Fu, Tianxiao Zhao, Arpan Sarkar, Feng Bao, Rani E. George, Nico Pierson, Long Cai, and Guo-Cheng Yuan. Giotto: a toolbox for integrative analysis and visualization of spatial expression data. *Genome Biology*, 22(1):78, Mar 2021.
- [4] Istituto dell’Enciclopedia Italiana Treccani. Informatica, n.d.
- [5] Y. Long, K. S. Ang, M. Li, K. L. K. Chong, R. Sethi, C. Zhong, H. Xu, Z. Ong, K. Sachaphibulkij, A. Chen, L. Zeng, H. Fu, M. Wu, L. H. K. Lim, L. Liu, and J. Chen. Spatially informed clustering, integration, and deconvolution of spatial transcriptomics with graphst. *Nature Communications*, 14(1):1155, Mar 2023.
- [6] National Human Genome Research Institute. Epigenomics fact sheet, 2020.
- [7] B. Pascal and C. Vozza. *Pensieri*. Guaraldi, 1995.
- [8] Rahul Satija. Analysis, visualization, and integration of spatial datasets with Seurat — satijalab.org. https://satijalab.org/seurat/articles/spatial_vignette.html.
- [9] Eric W Sayers, Jeffrey Beck, Evan E Bolton, Devon Bourexis, James R Brister, Kathi Canese, Donald C Comeau, Kathryn Funk, Sunghwan Kim, William Klimke, et al. Database resources of the national center

for biotechnology information. *Nucleic acids research*, 49(D1):D10–D17, 2021.

- [10] Simon Singh and Stefano Galli. *Codici & segreti*. Rizzoli Milano, 1999.
- [11] Cameron G Williams, Hyun Jae Lee, Takahiro Asatsuma, Roser Vento-Tormo, and Ashraful Haque. An introduction to spatial transcriptomics for biomedical research. *Genome medicine*, 14(1):68, 2022.

